



Tersedia online di www.sciencedirect.com

ScienceDirect

Ilmu Komputer Procedia 192 (2021) 4093–4102

Procedia
Computer Science

www.elsevier.com/locate/procedia

Konferensi Internasional ke-25 tentang Informasi & Rekayasa Berbasis Pengetahuan dan Cerdas Sistem

Sistem Absensi Cerdas Pengenalan Wajah menggunakan Deep Transfer Learning

Khawla Alhanae^{sebuah}, Mitha Alhammadi^{sebuah}, Nahla Almenhalise^{sebuah}, Maad Shatnawi^{sebuah*}

sebuah Departemen Teknologi Teknik Listrik, Sekolah Tinggi Teknologi, Abu Dhabi, UEA

Abstrak

Identifikasi wajah telah dianggap sebagai domain penelitian yang menarik dalam beberapa tahun terakhir karena memainkan peran otentikasi biometrik utama dalam beberapa aplikasi termasuk manajemen kehadiran dan sistem kontrol akses. Sistem manajemen kehadiran sangat penting untuk semua organisasi meskipun kompleks dan memakan waktu untuk mengelola log kehadiran reguler. Ada banyak teknik identifikasi manusia otomatis seperti biometrik, RFID, pelacakan mata, pengenalan suara. Wajah adalah salah satu biometrik yang paling banyak digunakan untuk autentikasi identitas manusia. Makalah ini menyajikan sistem absensi pengenalan wajah berbasis deep learning convolutional neural network. Kami memanfaatkan pembelajaran transfer dengan menggunakan tiga jaringan saraf convolutional terlatih dan melatihnya pada data kami.

© 2021 Para Penulis. Diterbitkan oleh Elsevier BV

Ini adalah artikel akses terbuka di bawah lisensi CC BY-NC-ND (<https://creativecommons.org/licenses/by-nc-nd/4.0>) Peer-review di bawah tanggung jawab komite ilmiah KES International.

Kata kunci: Ketik kata kunci Anda di sini, dipisahkan dengan titik koma ;

1. Perkenalan

Semua organisasi memerlukan sistem manajemen kehadiran untuk menyimpan catatan kehadiran staf mereka baik secara manual atau secara otomatis. Kehadiran harian siswa di kelas sangat penting untuk evaluasi kinerja dan kualitas

* Penulis yang sesuai. Telp: +971506151987.

Alamat email: maad.shatnawi@hct.ac.ae

pemantauan. Memanggil nama atau menandatangani di atas kertas adalah metode tradisional yang digunakan di sebagian besar organisasi, yang memakan waktu dan tidak aman [1]. Di sisi lain, sebagian besar sistem identifikasi manusia otomatis didasarkan pada metode tradisional seperti sidik jari, kata sandi, dan pemindaian ID. Namun semua cara tersebut memiliki beberapa keterbatasan seperti lupa password atau kehilangan KTP. Oleh karena itu, metode yang paling cocok untuk memastikan keamanan penuh dan menyimpan catatan sejarah adalah melalui sistem pengenalan wajah pintar [2]. Ini adalah bidang yang berkembang pesat belakangan ini, dan memainkan peran penting dalam keamanan karena merupakan teknik yang sangat tepat untuk mengidentifikasi dan memverifikasi orang [3] [4].

Pembelajaran transfer adalah bentuk pembelajaran mesin di mana model dibangun untuk tugas tertentu dan kemudian digunakan kembali pada tugas kedua sebagai titik awal untuk dimodifikasi. Ini digunakan dalam pembelajaran mendalam sebagai model pra-terlatih dalam visi komputer dan tugas pemrosesan bahasa alami untuk mengembangkan model jaringan saraf pada masalah ini [5]. Pembelajaran transfer sangat berguna dalam masalah pembelajaran yang mendalam karena sebagian besar masalah dunia nyata biasanya memiliki miliaran data berlabel, dan ini membutuhkan model yang kompleks [6]. Ini adalah teknik yang sempurna untuk pengoptimalan, penghematan waktu, dan mencapai kinerja yang lebih baik. Pengembang dapat menggunakan pembelajaran transfer untuk menggabungkan berbagai aplikasi menjadi satu. Mereka dapat dengan cepat melatih model baru untuk aplikasi yang kompleks. Selain itu, transfer learning merupakan alat yang baik untuk meningkatkan akurasi model computer vision [5].

Dalam karya ini kami menyajikan sistem kehadiran pengenalan wajah berdasarkan jaringan saraf convolutional pembelajaran mendalam (CNN). Kami memanfaatkan pembelajaran transfer dengan menggunakan tiga jaringan saraf convolutional terlatih dan melatihnya pada data kami yang berisi 10 kelas berbeda di mana setiap kelas menyertakan 20 gambar wajah. Ketiga jaringan tersebut menunjukkan kinerja yang sangat tinggi dalam hal akurasi prediksi yang tinggi dan waktu pelatihan yang masuk akal.

2. Jaringan Pra-Terlatih

Model CNN terlatih memiliki fitur berbeda yang penting saat memilih jaringan untuk menangani masalah tertentu. Ketepatan jaringan, kecepatan, dan ukuran adalah fitur yang paling signifikan. Umumnya, memilih jaringan berganti-ganti di antara fungsi-fungsi ini. Bagi orang yang ingin mempelajari algoritme atau menguji sistem yang sudah mapan, model pra-pelatihan adalah sumber dukungan yang sangat baik [7]. Tidak selalu layak untuk membangun model dari awal karena kendala waktu atau keterbatasan komputasi, itulah sebabnya ada model pra-pelatihan. Beberapa model CNN terlatih tersedia untuk umum [8]. Dalam pekerjaan ini, kami menyelidiki tiga jaringan pra-pelatihan; AlexNet, GoogleNet dan SqueezeNet.

2.1. AlexNet

Salah satu arsitektur jaringan saraf yang paling umum hingga saat ini adalah AlexNet. Ini telah digunakan untuk melatih jutaan gambar dan mengklasifikasikannya ke dalam kategori objek seperti wajah, buah, cangkir, pensil, dan hewan. Sebagai masukan, jaringan mengambil gambar dan mengeluarkan label untuk objek tersebut di dalam gambar. Juga, probabilitas untuk masing-masing kategori objek. Dimensi input jaringan adalah citra $227 \times 227 \times 3$ RGB [9] [10] [11] [12]. Arsitektur AlexNet ditunjukkan pada Gambar 1.


2.2. GoogleNet

Struktur GoogleNet memiliki kedalaman 22 lapisan selain 5 lapisan penyatuan [13]. Secara total, ada 9 modul inisiasi yang ditumpuk secara linear. Ini menggunakan 1×1 filter konvolusi juga. Net memiliki komputasi dan efisiensi memori yang sangat baik karena implementasi jaringan paralel dan pengurangan lapisan, ukuran model lebih kecil dari yang lain [9] [12]. Arsitektur GoogleNet disajikan pada Gambar 2.


2.3. SqueezeNet

SqueezeNet adalah jaringan saraf konvolusional sedalam 18 lapisan. Jaringan terlatih akan mengkategorikan gambar ke dalam 1000 kategori objek. Untuk berbagai gambar, jaringan telah mempelajari representasi fungsi yang kompleks. Tujuan menggunakan SqueezeNet adalah untuk membangun jaringan saraf yang lebih kecil dengan kumpulan data kecil yang bisa


mengintegrasikan ke dalam memori komputer dengan lebih mudah dan dapat dikomunikasikan melalui jaringan komputer dengan lebih mudah [9] [14] [12]. Arsitektur SqueezeNet Net ditunjukkan pada Gambar 3.



Gambar 1. Arsitektur AlexNet [12].



Gambar 2. Arsitektur GoogleNet [12].



Gambar 3. Arsitektur SqueezeNet [12].

3. Pekerjaan Terkait

Identifikasi wajah telah diteliti oleh beberapa peneliti. Salah satu solusi yang ada [15] menggunakan teknik pengenalan wajah yang menggunakan fitur yang berasal dari koefisien Discrete Cosine Transform (DCT), bersama dengan

classifier berdasarkan Self Organizing Map (SOM) classifier. Di MATLAB, metode diuji dan berisi subjek dengan berbagai ekspresi wajah. Perangkat dapat mencapai tingkat pengenalan 81,36% selama 10 percobaan berturut-turut dengan menyiapkan program ini selama kurang lebih 850 zaman. Ruang fitur yang berkurang, ditentukan untuk sistem ini. Ini membuat skema diadaptasi dengan baik untuk penerapan perangkat keras real-time berbiaya rendah.

Arsenovic dkk. [16] mengusulkan sistem kehadiran pengenalan wajah berbasis pembelajaran yang mendalam. Model ini terdiri dari beberapa langkah kunci yang dikembangkan menggunakan teknik paling modern yang tersedia saat ini seperti kaskade CNN untuk deteksi wajah dan CNN untuk pembuatan penyisipan wajah. Pada kumpulan data terbatas dari gambar wajah asli karyawan di dunia real-time, akurasi keseluruhannya adalah 95,02%. Model pengenalan wajah yang diusulkan juga dapat digunakan di sistem lain.

Fu dkk. [17] mengusulkan solusi yang mengintegrasikan dua algoritma pembelajaran mendalam, deteksi wajah Multi-Task Cascade Convolution Neural Network (MTCNN), dan pengenalan Centre-Face, untuk menciptakan sistem kehadiran otomatis di ruang kelas universitas. Sistem akan melaporkan ketiga pelanggaran disiplin kelas untuk kehadiran otomatis: ketidakhadiran, keterlambatan, dan pulang lebih awal, menurut sejumlah temuan eksperimen yang signifikan. Setelah kelas, meja kehadiran dengan status belajar semua siswa secara otomatis terdaftar. Sistem mengenali wajah dengan cepat, hanya membutuhkan 100 milidetik per frame dan mencapai akurasi tinggi. Model ini memiliki tingkat akurasi 98,87%, tingkat positif sejati di bawah 1/1000, dan tingkat positif palsu 93,7 persen.


Zulfikar dkk. [18] mengusulkan sistem pengenalan wajah berdasarkan jaringan saraf konvolusional yang mendeteksi wajah dalam gambar input menggunakan detektor wajah Viola-Jones [19] dan secara otomatis mengekstrak fitur wajah dari wajah yang terdeteksi menggunakan CNN terlatih untuk pengenalan. Untuk pelatihan jaringan saraf konvolusional yang efisien, database gambar wajah subjek yang sangat besar telah dibuat, yang ditambah untuk meningkatkan jumlah gambar per subjek dan menyediakan berbagai kondisi iluminasi dan kebisingan. Selain itu, untuk pengenalan wajah yang dalam, model CNN pra-terlatih yang dioptimalkan dan serangkaian parameter hiper dipilih secara eksperimental. Kemanjuran pengenalan wajah dalam sistem otentikasi biometrik otomatis ditunjukkan dalam temuan eksperimental yang menjanjikan dengan akurasi keseluruhan 98,76%.

4. Metode

Pendekatan yang diusulkan terdiri dari beberapa tahap: pengumpulan data, pra-pemrosesan data, augmentasi data, pelatihan dan validasi CNN, dan pengujian sistem.

4.1. Pengumpulan data

Kumpulan data kami adalah kumpulan 200 gambar yang dikumpulkan menggunakan kamera depan iPhone 12 yang merupakan lensa 12 megapiksel, f/2.2. Data diklasifikasikan ke dalam 10 kelas, masing-masing kelas mencakup 20 citra. 10 kelas tersebut mewakili 10 orang dari kedua jenis kelamin seperti yang ditunjukkan pada Gambar 4.




Gambar 4. Dataset.

4.2. Pemformatan Data

Data yang dikumpulkan digunakan dalam format file JPG. Ukuran gambar berkisar antara 3,00 MB dan 4,00 MB. Setiap net memiliki ukuran input yang berbeda. Oleh karena itu, kami harus mengubah ukuran gambar ke dimensi input jaringan yang sesuai. SqueezeNet dan AlexNet menggunakan 227×227 , sedangkan GoogleNet menggunakan 224×224 . Semua gambar diambil dalam warna RGB yang bagus untuk mengekstraksi fitur yang tepat.

4.3. Augmentasi Data

Augmentasi data adalah alat yang digunakan untuk menambah jumlah data dengan memasukkan salinan yang sedikit diubah dari data yang ada atau data sintetik yang baru diproduksi dari data yang ada. Ini mengatur dan membantu dalam pelatihan model pembelajaran mesin untuk meminimalkan overfitting. Dalam pembelajaran mendalam, augmentasi data datang dalam bentuk transformasi geometris, flipping, perubahan warna, cropping, rotasi, injeksi noise, dan penghapusan acak digunakan untuk menyempurnakan gambar [8]. Dalam jaringan terlatih kami, kami menggunakan augmentasi data dengan mengambil banyak gambar dari berbagai sudut, lingkungan dan kondisi, orientasi, lokasi, dan kecerahan seperti yang ditunjukkan pada Gambar. 5. Setelah mengimpor data kami ke jaringan, kami menerapkan dua jenis augmentasi data yang mana adalah rotasi dan penskalaan. Rotasi acak dilakukan pada setiap gambar dengan sudut dalam kisaran -90 hingga 90 derajat. Penskalaan acak dilakukan pada setiap gambar dengan faktor dalam kisaran 1 hingga 2.



Gambar 5. Contoh augmentasi data.

4.4. Pilihan jaringan pra-terlatih

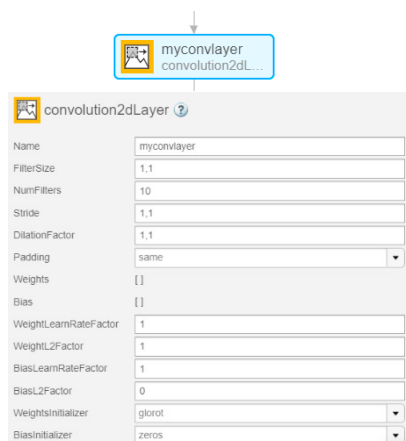
Untuk melatih jaringan saraf konvolusi pada data kami, kami memilih 3 jaring untuk digunakan yaitu, SqueezeNet, AlexNet, dan GoogleNet. SqueezeNet adalah CNN kecil dan membutuhkan lebih sedikit komunikasi antar server selama pelatihan terdistribusi. CNN yang lebih kecil juga lebih mudah diimplementasikan pada perangkat keras dengan memori terbatas, seperti fieldprogrammable gate array (FPGA).

AlexNet dapat dengan mudah meneruskan fitur yang dipelajari ke tugas khusus dengan jumlah gambar pelatihan yang lebih sedikit. AlexNet dikembangkan untuk meningkatkan kinerja tantangan ImageNet. Ini adalah salah satu jaringan Deep convolutional pertama yang mencapai akurasi yang signifikan. Masalah overfitting juga diselesaikan oleh AlexNet dengan menggunakan lapisan drop-out di mana koneksi terputus dengan probabilitas $p=0,5$ selama pengujian. Probabilitas 0,5 dipilih karena merupakan probabilitas terbaik untuk mencocokkan spesifikasi bersih dan opsi pelatihan. Ini ditetapkan setelah banyak percobaan dan perubahan. Meskipun hal ini mencegah overfitting jaringan dengan membebaskannya dari minima lokal yang buruk, jumlah iterasi yang diperlukan untuk konvergensi juga menjadi dua kali lipat.

Modul awal dalam arsitektur GoogleNet memecahkan sebagian besar tantangan yang dihadapi jaringan besar. GoogleNet mencetak tingkat kesalahan 6,67% yang mendekati kinerja tingkat manusia. Arsitekturnya terdiri dari 22 lapisan Deep CNN yang mengurangi jumlah parameter menjadi 4 juta (60 juta dibandingkan dari AlexNet).

4.5. Penyetelan jaringan pra-terlatih


Di masing-masing dari tiga jaring yang digunakan, kami menyetel parameter jaringan pra-terlatih yang merupakan lapisan konvolusi 2D dan lapisan keluaran klasifikasi. Di desainer jaringan dalam, kami mengubah ukuran filter menjadi 1×1 , dan jumlah filter menjadi 10 karena kami memiliki 10 kelas data seperti yang ditunjukkan pada Gambar. 6. Kami memodifikasi lapisan keluaran klasifikasi agar sesuai dengan klasifikasi dan label keluaran kami.



Gambar 6. Penyetelan Lapisan Konvolusi.

4.6. Pelatihan

Prosedur umum saat melatih jaringan apa pun menggunakan pembelajaran transfer dimulai dengan memodifikasi parameter milik arsitektur dasar. Ini termasuk memilih tingkat pembelajaran yang sesuai, waktu pelatihan, jumlah zaman, dan frekuensi validasi. Ketika kecepatan awal terlalu rendah, proses pelatihan mungkin terhenti, dan ketika kecepatan terlalu tinggi, proses pelatihan mungkin menjadi tidak stabil atau terlalu cepat mempelajari kumpulan bobot yang kurang optimal. Oleh karena itu, kami memilih tingkat pembelajaran awal untuk ditetapkan ke 0,0001, frekuensi validasi adalah 10, dan zaman maksimum adalah 30 karena harus setinggi mungkin untuk menghilangkan kegagalan jeda pelatihan berdasarkan tingkat kesalahan. Untuk lebih spesifik, zaman adalah satu siklus pembelajaran di mana pelajar terpapar ke seluruh kumpulan data pelatihan. Juga, ukuran batch minimum sama dengan 11, ini sesuai dengan kebutuhan memori (8,00 GB) dari perangkat keras CPU yang beroperasi menggunakan 1,8 GHz. Semakin tinggi jumlah epoch, semakin tinggi akurasi jaringan. Oleh karena itu, kami harus memilih nomor yang lebih besar. Kumpulan data secara acak dibagi menjadi dua bagian: 70% data digunakan untuk pelatihan dan 30% data digunakan untuk validasi. Parameter pelatihan diilustrasikan pada Gambar. 7.



Gambar 7. Opsi Pelatihan.


5. Hasil dan Pembahasan

Melatih SqueezeNet membutuhkan total 30 epoch dengan 12 iterasi per epoch agar jaringan dapat melatih data dengan sangat baik dan memvalidasinya. Setelah 360 iterasi, diperoleh akurasi validasi sebesar 98,33%. Proses pelatihan memakan waktu 26 menit dan 53 detik. Selain itu, frekuensi validasi dilakukan dalam proses 10 iterasi untuk memastikan sistem dilatih dengan baik tetapi tidak overfitting data.



Pelatihan GoogleNet membutuhkan total 30 epoch dengan 12 iterasi per epoch agar jaringan dapat melatih data dengan sangat baik dan memvalidasinya. Setelah 360 iterasi, akurasi validasi mencapai 93,33%. Jaringan membutuhkan waktu 39 menit dan 21 detik untuk menyelesaikan pelatihan. Selain itu, validasi dilakukan dalam proses 10 iterasi untuk memastikan bahwa sistem dilatih dengan baik tetapi tidak melakukan overfitting data.

Melatih AlexNet menggunakan total 60 epoch dengan 12 iterasi per epoch agar jaringan dapat melatih data dengan sangat baik dan memvalidasinya. Setelah 720 iterasi, akurasi validasi mencapai 100% yang merupakan akurasi sempurna yang menunjukkan jaringan yang terlatih dengan baik. Jaringan membutuhkan waktu 76 menit untuk menyelesaikan pelatihan, yang merupakan waktu pemrosesan yang lama dibandingkan dengan dua jaringan sebelumnya. Selain itu, validasi dilakukan dalam proses 10 iterasi untuk memastikan bahwa sistem dilatih dengan baik tetapi tidak melakukan overfitting data.


Kami menggunakan sistem yang terdiri dari satu CPU yang beroperasi menggunakan 1,8 GHz dengan RAM 8,00 GB. Seperti yang disajikan pada Gambar. 8, kami menggunakan tingkat pembelajaran awal yang sama, iterasi maksimum dan CPU tunggal untuk tiga jaringan sementara jumlah zaman berbeda untuk setiap jaringan. Terlihat bahwa AlexNet adalah jaringan terbaik dalam hal akurasi validasi tetapi memiliki waktu pelatihan terlama karena banyaknya parameter. SqueezeNet merupakan pilihan terbaik kedua yang memberikan akurasi sebesar 98,33% dengan waktu pelatihan minimum yaitu 26 menit 53 detik. GoogleNet memberikan akurasi terendah di antara ketiga jaringan tersebut. Hasil pelatihan dan validasi ketiga jaringan dirangkum dalam Tabel 1.



Results	
Validation accuracy:	98.33%
Training finished:	Reached final iteration
Training Time	
Start time:	09-Jan-2021 17:02:37
Elapsed time:	26 min 53 sec
Training Cycle	
Epoch:	30 of 30
Iteration:	360 of 360
Iterations per epoch:	12
Maximum iterations:	360
Validation	
Frequency:	10 iterations
Other Information	
Hardware resource:	Single CPU
Learning rate schedule:	Constant
Learning rate:	0.0001

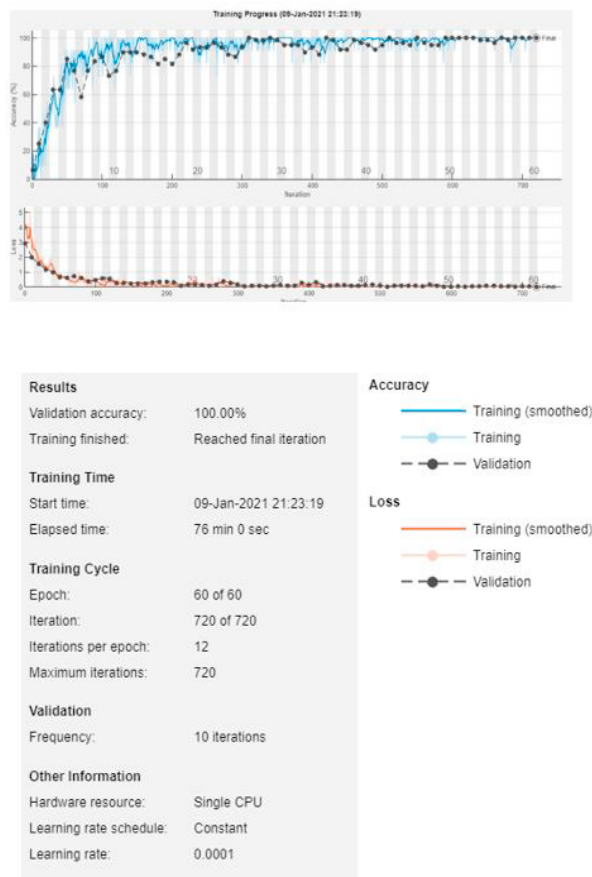


Results	
Validation accuracy:	93.33%
Training finished:	Reached final iteration
Training Time	
Start time:	07-Jan-2021 14:49:19
Elapsed time:	39 min 21 sec
Training Cycle	
Epoch:	30 of 30
Iteration:	360 of 360
Iterations per epoch:	12
Maximum iterations:	360
Validation	
Frequency:	10 iterations
Other Information	
Hardware resource:	Single CPU
Learning rate schedule:	Constant
Learning rate:	0.0001



(sebuah)

(b)



(c)


Gambar 8. Hasil pelatihan dan validasi (a) SqueezeNet; (b) GoogleNet; (c) AlexNet.

Tabel 1. Hasil Pelatihan Convolution Neural Network (CNN).

Model	Tingkat Pembelajaran	Zaman	Akurasi Validasi	Waktu berlalu	Sumber Daya Perangkat Keras	Iterasi Maks
SqueezeNet	0,0001	30	98,33%	26 menit 53 detik	CPU tunggal	360
GoogleNet	0,0001	30	93,33%	39 menit 21 detik	CPU tunggal	360
AlexNet	0,0001	60	100%	76 menit 0 detik	CPU tunggal	720

Saat diuji pada gambar tak terlihat dari sepuluh kelas yang berbeda, ketiga model CNN berhasil mengenali wajah dengan keyakinan prediksi yang sangat tinggi. Persentase yang ditampilkan di bagian atas gambar mengacu pada tingkat kepercayaan jaringan terlatih dalam memprediksi label yang sesuai. Tingkat kepercayaan yang sangat tinggi menunjukkan bahwa model berhasil memprediksi citra. Gambar 9a, 9b, dan 9c masing-masing mengilustrasikan contoh hasil yang dicapai oleh SqueezeNet, GoogleNet, dan AlexNet.

Untuk menganalisis hasilnya, kami menggunakan tingkat pembelajaran awal yang sama untuk jaringan, iterasi maksimum, CPU tunggal sementara jumlah zaman berbeda untuk setiap jaringan. Dapat kita amati bahwa AlexNet adalah jaringan terbaik yang digunakan untuk melatih data karena memiliki akurasi validasi tertinggi meskipun membutuhkan durasi pelatihan terlama. SqueezeNet merupakan pilihan terbaik kedua yang memberikan akurasi sebesar 98,33% dengan waktu tempuh minimum yaitu 26 menit 53 detik. Jaringan terbaik ketiga adalah GoogleNet karena memberikan akurasi terendah di antara ketiga jaringan tersebut.



Gambar 9. Hasil Pengujian (a) SqueezeNet; (b) GoogleNet; (c) AlexNet.

Perbandingan metode yang diusulkan dengan yang diperoleh dari metode sebelumnya ditunjukkan pada Tabel 2. Hasil yang diperoleh pada Tabel 2 didasarkan pada dataset kami. Terlihat jelas bahwa pendekatan kami mengungguli pendekatan lain.

Tabel 2. Perbandingan pendekatan pengenalan wajah.

Mendekati	Model CNN	Ketepatan
Fu dkk. [17]	ResNet-101	99,7%
Zulfikar dkk. [18]	Resnet50	98,3%
Pendekatan Kami	AlexNet	100%

6. Kesimpulan

Makalah ini menyajikan sistem absensi pengenalan wajah berbasis deep learning. Kami memanfaatkan pembelajaran transfer dengan menggunakan tiga jaringan saraf convolutional terlatih dan melatihnya pada data kami. Jika dibandingkan dengan pendekatan lain, sistem menunjukkan kinerja yang sangat tinggi dalam hal akurasi prediksi yang tinggi dan waktu pelatihan yang masuk akal. Ketiga jaringan tersebut adalah SqueezeNet, GoogleNet dan AlexNet dimana mereka mencapai akurasi validasi masing-masing sebesar 98,33%, 93,33% dan 100%. Pendekatan yang diusulkan dapat digunakan dalam sistem kehadiran dan akses pintu di banyak organisasi seperti sektor pemerintah dan swasta, bandara, sekolah, dan universitas.

Pekerjaan ini dapat diperpanjang dengan menyelidiki lebih banyak model CNN terlatih dan dengan memasukkan lebih banyak data gambar wajah manusia. Sangat menarik untuk menyelidiki penerapan model ini untuk tugas identifikasi manusia bertopeng.

Referensi

- [1] M. Karunakar, CA Sai, K. Chandra dan KA Kumar, "PintarSistem Pemantauan Kehadiran (SAMS): Berbasis Pengenalan Wajah Sistem Absensi untuk Lingkungan Kelas," *Jurnal Internasional untuk Perkembangan Terkini dalam Sains dan Teknologi*, vol. 4, tidak. 5, hlm. 194-201, 2020.
- [2] S. Bhattacharya, GS Nainala, P. Das dan A. Routray, "Sistem Pemantauan Kehadiran Cerdas (SAMS): Sistem Kehadiran Berbasis Pengenalan Wajah untuk Lingkungan Kelas," di *2018 IEEE 18th International Conference on Advanced Learning Technologies (ICALT)*, 2018.
- [3] G. Hua, M.-H. Yang, E. Belajar-Miller, Y. a. TM Ma, DJ Kriegman dan TS Huang, "Pengantar bagian khusus tentang pengenalan wajah dunia nyata," *Transaksi IEEE pada Analisis Pola dan Kecerdasan Mesin*, vol. 33, hlm. 1921--1924, 2011.
- [4] FP Filippidou dan GAPapakostas, "Pengenalan Wajah Sampel Tunggal Menggunakan Jaringan Syaraf Konvolusional untuk Sistem Absensi Otomatis," dalam *2020 Konferensi Internasional Keempat tentang Komputasi Cerdas dalam Ilmu Data (ICDS)*, 2020.
- [5] J. Brownlee, "Int yang Lembut produksi Transfer Learning for Deep Learning," 20 Desember 2017. [Online]. Tersedia: <https://machinelearningmastery.com/transfer-learning-for-deeplearning/#:~:text=Transfer%20learning%20is%20a%20machine,model%20on%20a%20second%20task>.

- [6] M. Xu, W. Cheng, Q. Zhao, L. Ma dan F. Xu, Pengenalan ekspresi wajah berdasarkan pembelajaran transfer dari jaringan konvolusional yang dalam, IEEE, 2015, hlm. 702--708.
- [7] P. Marcelino, "Mentransfer pembelajaran dari model pra-pelatihan," *Menuju Ilmu Data*, 2018.
- [8] A. Gandhi, "Augmentasi Data | Cara menggunakan Deep Learning saat Anda memiliki Data Terbatas—Bagian 2," 2018. [Online]. Tersedia: <https://nanonets.com/blog/data-augmentation-how-to-use-deep-learning-when-you-have-limited-data-part-2/>.
- [9] TM Ayyar, "Praktis percobaan untuk membandingkan model LeNet, AlexNet, VGG dan ResNet dengan keunggulan dan kerugian.," [Online]. Tersedia: <https://tejas-mohanayyar.medium.com/a-eksperimen-praktis-untuk-membandingkan-lenet-alexnet-vgg-andresnet-model-dengan-kelebihannya-d932fb7c7d17>.
- [10] A. Khvostikov, K. Aderghal, J. Benois-Pineau, A. Krylov dan G. Catheline, "3D CNN-berdasarkan klasifikasi menggunakan sMRI dan MD-DTI gambar untuk studi penyakit Alzheimer, " *pracetak arXiv arXiv:1801.05968*, 2018.
- [11] S.-H. Tsang, "Ulasan: AlexNet, CaffeNet--Pemenang ILSVRC 2012 (Klasifikasi Gambar)," *Perusahaan Menengah*, vol. 9, 2018.
- [12] Z. Guo, Q. Chen, G. a. XY Wu, R. Shibasaki dan X. Shao, "Identifikasi bangunan desa berdasarkan konvolusi ansambel neural jaringan," *Sensor*, vol. 17, tidak. 11, hal. 2487, 2017.
- [13] R. Alake, "Deep Learning: Penjelasan GoogLeNet," 23 Desember 2020. [Online]. Tersedia: <https://towardsdatascience.com/deep-belajar-googlenet-dijelaskan-de8861c82765>.
- [14] V. Kurama, "Tinjauan De Populerep Belajaring Architectures: AlexNet, VGG16, dan GoogleNet," 1 Juni 2020. [Online]. Tersedia: <https://blog.paperspace.com/popular-deep-learning-architectures-alexnet-vgg-googlenet/>.
- [15] N. Soni, M. Kumar dan G. Mathur, "Pengenalan Wajah menggunakan SOM Neural Jaringan dengan Ekstraksi Fitur Wajah yang Berbeda Teknik," *Jurnal Internasional Aplikasi Komputer*, vol. 76, tidak. 3, hlm. 7-11, 2013.
- [16] M. Arsenovic, S. a. AA Sladojevic dan D. Stefanovic, "FaceTime—Kehadiran pengenalan wajah berbasis pembelajaran mendalam sistem," *2017 IEEE 15th International Symposium on Intelligent Systems and Informatics (SISY)*, hlm. 000053--000058, 2017.
- [17] R. Fu, D. Wang, D. Li dan Z. Luo, "Kehadiran di kelas universitas berdasarkan pembelajaran mendalam," *2017 10th International Conference on Intelligent Computation Technology and Automation (ICICTA)*, hlm. 128--131, 2017.
- [18] M. Zulfiqar, F. Syed, MJ Khan dan K. Khurshid, "Deep Face Recognition for Biometric Authentication," dalam *Konferensi Internasional tentang Teknik Listrik, Komunikasi, dan Komputer (ICECCE) 2019*, 2019.
- [19] Y.-T. Wang, "Analisis algoritme deteksi wajah Viola-Jones," *Pemrosesan Gambar On Line*, vol. 4, hlm. 128--148, 2014.